

ESTRATEGIA DE OPTIMIZACIÓN DE COSTOS Y RECURSOS

Sistema: Asesor Financiero IA

Estrategia de Modelos: Enrutamiento Híbrido Multimodelo (Anthropic + OpenAI)

1. Matriz de Decisión y Selección Estratégica de Modelos

En sistemas de grado empresarial, recurrir a un modelo de razonamiento superior para tareas mecánicas representa un desperdicio financiero. Se implementa una arquitectura de enrutamiento selectivo (Model Routing), asignando cada tarea al modelo óptimo en costo y rendimiento:

- **Triage de Email y Normalización:**
 - **Modelo Asignado:** GPT-4o-mini
 - **Tipo de Carga:** Mecánica / Determinista
 - **Justificación de Negocio:** Alta velocidad de inferencia, costo mínimo por millón de tokens (\$0.15 USD en Input / \$0.60 USD en Output) y precisión estricta para formatear texto a números y fechas sin alucinaciones.
- **Lectura Densa de Extractos Financieros:**
 - **Modelo Asignado:** Claude 3.5 Sonnet
 - **Tipo de Carga:** Cognitiva / Densa
 - **Justificación de Negocio:** Gran ventana de contexto (200.000 tokens), lectura avanzada de tablas financieras complejas y capacidad para interpretar conceptos ambiguos en los extractos bancarios.
- **Generación de Diagnóstico e Idea Semilla:**
 - **Modelo Asignado:** Claude 3.5 Sonnet
 - **Tipo de Carga:** Creativa / Estratégica
 - **Justificación de Negocio:** Capacidad para redactar recomendaciones empáticas y humanas, utilizando Prompt Caching para mantener en memoria las reglas de ahorro del usuario.
- **Auditoría Histórica Mensual Masiva:**
 - **Modelo Asignado:** Claude 3.5 Sonnet (Message Batches API)
 - **Tipo de Carga:** Asíncrona / Procesamiento por Lotes
 - **Justificación de Negocio:** Conciliación en segundo plano (con entrega en hasta 24 horas) para procesar resúmenes históricos con un 50% de descuento directo en el costo de tokens.

2. Demostración Matemática de Ahorro Presupuestario

2.1 Eficiencia con Message Batches API (50% de Ahorro Directo)

Para la auditoría y conciliación masiva periódica de resúmenes históricos (procesamiento en segundo plano sin necesidad de respuesta en tiempo real):

- **Volumen:** 500 extractos densos al año.
- **Consumo promedio por extracto:** 12.000 tokens de entrada (documento parseado) + 1.000 tokens de salida estructurada.
- **Tokens Totales de Entrada:** $500 \times 12.000 = 6.000.000$ tokens (6M).
- **Tokens Totales de Salida:** $500 \times 1.000 = 500.000$ tokens (0.5M).

Cálculo a Tarifa Estándar (Llamada Real-time API):

- Costo Input: $6M \times \$3.00 \text{ USD} / M = \18.00 USD
- Costo Output: $0.5M \times \$15.00 \text{ USD} / M = \7.50 USD
- **Costo Total Estándar:** $\$25.50 \text{ USD}$

Cálculo con Anthropic Message Batches API (50% de Descuento):

- Costo Input en Batch: $6M \times \$1.50 \text{ USD} / M = \9.00 USD
- Costo Output en Batch: $0.5M \times \$7.50 \text{ USD} / M = \3.75 USD
- **Costo Total con Batch:** $\$12.75 \text{ USD}$
- **Ahorro Certificado:** 50.0% ($\$12.75 \text{ USD}$ de ahorro directo por cada lote de 500 extractos).

2.2 Eficiencia con Prompt Caching en Flujos Recurrentes

El sistema inyecta de forma estática al inicio del prompt (Prefix) el catálogo de categorías, equivalencias de moneda y directrices de ahorro del usuario (bloque equivalente a 4.500 tokens).

- **Condición de Anthropic:** Supera el umbral mínimo de 1.024 tokens para activar el caché en Claude 3.5 Sonnet.
- **Frecuencia operativa:** 200 consultas o clasificaciones recurrentes al mes.
- **Costo de Escritura en Caché (1ª llamada):** $\$3.75 \text{ USD} / M$ tokens.
- **Costo de Lectura en Caché (llamadas 2 a 200):** $\$0.30 \text{ USD} / M$ tokens (90% de descuento sobre el precio base).

Costo sin Prompt Caching (Llamadas tradicionales):

- Total tokens de entrada: $200 \text{ llamadas} \times 4.500 \text{ tokens} = 900.000 \text{ tokens}$ (0.9M).
- Costo de entrada: $0.9M \times \$3.00 \text{ USD} / M = \mathbf{\$2.70 \text{ USD}}$

Costo con Prompt Caching:

- Primera llamada (escritura): $0.0045M \times \$3.75 \text{ USD} / M = \0.0169 USD
- 199 llamadas siguientes (lectura con descuento): $(199 \times 0.0045M) \times \$0.30 \text{ USD} / M = 0.8955M \times \$0.30 \text{ USD} / M = \$0.2686 \text{ USD}$
- Costo total de entrada: $\$0.0169 \text{ USD} + \$0.2686 \text{ USD} = \mathbf{\$0.2855 \text{ USD}}$

- **Ahorro en Tokens de Entrada:** 89.42% (reducción de costo en un factor cercano a 9.5x).

3. Gobernanza de Tokens y Guardrails Financieros

1. **Parámetro max_tokens Acotado:** Configurado estrictamente en **800 tokens** en los nodos de generación de recomendaciones para evitar respuestas innecesariamente largas (Prompt Bloat).
 2. **Filtro de Descarte Temprano:** Nodos de código y filtros deterministas descartan correos publicitarios o respuestas automáticas antes de invocar los modelos LLM, manteniendo en \$0 el costo de correos irrelevantes.
 3. **Control de Bucles en Agentes:** Límite estricto de **5 iteraciones máximas** en el ciclo ReAct del agente en n8n para blindar el flujo ante fallos de conexión o llamadas repetidas a herramientas.
- 1.